

Cronograma de Execução da Pesquisa (v2)

Supervisor Agent for LLM-Assisted Legacy Software Modernization

Junho de 2026

Duração: 24 meses (junho de 2026 a maio de 2028).

Visão Geral da Estrutura

A pesquisa segue uma arquitetura de *Design Science Research* (DSR) com dois ciclos completos de coleta, análise e escrita, permitindo replicação interna e publicação em múltiplos venues. O enquadramento metodológico combina princípios de DSR, experimentação em engenharia de software e desenho experimental orientado a hipóteses, conforme proposto por Hevner et al., Wohlin et al. e Basili et al. [4, 8, 1]. Em termos de problema aplicado, o cronograma foi concebido para sustentar a modernização de software legado com foco em manutenibilidade, rastreabilidade e avaliação rigorosa de qualidade, em linha com a literatura de código legado, refatoração e qualidade de software [2, 3, 7, 5].

Os três ciclos DSR, nomeadamente Relevance, Design e Rigor, distribuem-se ao longo de 24 meses, com decisões *go/no-go* explícitas em marcos críticos. O objetivo é detectar anomalias cedo, congelar o protocolo no momento apropriado e sustentar refinamento iterativo sem comprometer a validade confirmatória.

Ciclo 1: Relevância (Junho–Setembro de 2026 / Meses 1–4)

A pesquisa inicia-se com o ciclo de relevância, estabelecendo a fundação científica do projeto. Durante os primeiros quatro meses, valida-se o problema de pesquisa, operacionalizam-se as *Research Questions* (RQs), define-se o corpus de experimentação e congela-se o protocolo via pré-registro. No primeiro mês, finaliza-se a especificação de requisitos com base em Volere, ajustando prioridades *Must*, *Should* e *Could* com o orientador e estabilizando o documento de requisitos para que a fase seguinte se inicie com escopo bem definido.

Em paralelo, integra-se a *Systematic Literature Review* na seção de *Related Work*, identificando trabalhos próximos como SWE-bench, SWE-agent, Plan4Code e OpenHands, além de abordagens clássicas de refatoração e modernização [9, 2, 3]. A partir disso, constrói-se um *Gap Ledger* que explicita a arte prévia mais próxima, o que cada trabalho

cobre, o que permanece em aberto e como cada contribuição proposta responde a uma lacuna específica.

Na sequência, revisa-se o enquadramento de DSR mapeando os sete *guidelines* de Hevner et al. ao projeto. Esse mapeamento cobre o artefato como objeto de design, a relevância do problema, a avaliação do design, a contribuição de pesquisa, o rigor metodológico, o design como processo de busca e a comunicação científica [4]. Em paralelo, operacionaliza-se cada RQ. Para RQ1, definem-se hipótese, variáveis dependentes, protocolo de inspeção e validação manual com κ . Para RQ2 a RQ4, definem-se hipóteses sobre o delta de qualidade estrutural, testes pareados e critérios de sucesso. Para RQ3, especifica-se consistência sob paráfrases semanticamente equivalentes. Para RQ4a, define-se o efeito esperado de configurações de *strictness*.

Da terceira semana de junho até o final de julho, identifica-se e valida-se o corpus experimental: cinco repositórios públicos em C#, com licenças permissivas, *issue trackers* funcionais e equilíbrio entre sistemas legados e sistemas ativamente mantidos. Cada repositório é avaliado quanto à presença de violações observáveis por análise estática, volume de issues potencialmente tratáveis, atividade da comunidade e disponibilidade de *git hashes* e artefatos de build. Em seguida, desenha-se o experimento com *flowchart* de execução, definindo condições supervisionada e baseline, coleta de saídas, validação humana, survey e auditoria de *provenance*.

Em agosto, o protocolo é pré-registrado no *Open Science Framework*. Hipóteses, variáveis, testes estatísticos, corpus e procedimento são congelados e vinculados publicamente. Isso reduz margem para *p-hacking* e fortalece a validade conclusiva do estudo [8]. Até o final do mesmo período, redige-se um primeiro rascunho de introdução e trabalhos relacionados. Ao final de M4, toma-se a decisão *go/no-go*: se as RQs estiverem operacionalizadas, o corpus validado e o pré-registro publicado, o projeto avança para a fase de design; caso contrário, a fase de relevância é estendida por duas a três semanas.

Ciclo 2: Design (Outubro de 2026–Fevereiro de 2027 / Meses 5–9)

O ciclo de design inicia-se em outubro de 2026 com o objetivo de resolver os gaps de implementação que impedem experimentos reproduzíveis. Durante cinco meses, o foco recai sobre controles de determinismo, captura de dados SOLID, endurecimento do *harness* experimental e validação do pipeline por meio de um piloto com dez issues.

Na primeira semana de M5, adicionam-se os parâmetros `temperature=0` e `seed` ao cliente LLM, garantindo persistência desses valores nos logs de cada *trial*. A premissa é simples: com temperatura nula e semente fixa, a execução deve reduzir variabilidade residual ao mínimo observável. Em seguida, executa-se um microestudo de determinismo com 5 a 10 issues, cada uma rodada duas vezes nas mesmas condições, para medir a variância dos outputs.

Em paralelo, integra-se o motor de análise estática para observar princípios SOLID.

Define-se uma versão específica de regras, seja por SonarQube, seja por *Roslyn analyzers*, e documenta-se o mapeamento entre princípios como SRP, OCP e DIP e seus indicadores operacionais. Implementa-se também a captura do número de violações antes e depois de cada mudança, armazenando tudo em um esquema versionado de *TrialResult*.

Ainda em outubro, implementa-se a condição baseline *zero-shot*. Para isso, configura-se `nfr_focus=[]` e `relationship_depth=0` no *IntentPlanner*, desligando a supervisão taxonômica. A condição baseline preserva modelo, temperatura, semente e pipeline de avaliação, diferindo apenas pela ausência de supervisão explícita. Também se completa o wireamento das rotinas `_run_supervised_trial` e `_run_baseline_trial` em `src/evaluation/reproducibility_experiment.py`, armazenando os artefatos gerados em arquivos JSON versionados.

Em novembro, implementa-se a captura completa de *execution traces*. Cada execução passa a registrar repositório, revisão, aprovações, prompts, saídas intermediárias, *timestamps*, configuração e versão do modelo. Na mesma etapa, define-se um *testability gate*, registrando status de build, status de testes, contagem de testes adicionados e, quando possível, delta de cobertura. A interpretação do resultado passa a depender de o código ao menos compilar e não quebrar a suíte essencial.

Ainda em novembro, coletam-se métricas adicionais de qualidade, como complexidade ciclomática, cobertura, duplicação, aderência a convenções e sinais de segurança. No mesmo mês, substitui-se o *scorer* de similaridade de código por `microsoft/codebert-base`, mais adequado ao domínio de código-fonte. Em dezembro, implementa-se o protocolo de paráfrases para RQ3, definindo dez estilos semanticamente equivalentes, mas superficialmente distintos, e constrói-se um executor capaz de gerar e rodar essas variantes sob as duas condições experimentais.

No mesmo período, adicionam-se testes unitários mais abrangentes para *IntentPlanner* e *ExplanationService*, cobrindo validade de esquema, determinismo e casos de borda. Em janeiro, realiza-se um piloto com dez issues. Parte desse piloto observa a cobertura explícita de SRP, OCP e DIP nos planos; a outra parte mede delta SOLID, validação por três ou mais engenheiros e coerência das paráfrases. Ao final de fevereiro, a decisão *go/no-go* de M9 exige CI verde, $\kappa \geq 0,6$, delta mensurável em ao menos 8 das 10 issues, comportamento determinístico suficientemente estável e cobertura de design de pelo menos 80%.

Ciclo 3a: Rigor — Coleta I (Março–Agosto de 2027 / Meses 10–15)

Com a aprovação do marco M9, inicia-se a primeira coleta em escala completa. Durante seis meses, executam-se experimentos pareados entre condição supervisionada e condição baseline, mantendo o protocolo congelado. Para RQ1, o *IntentPlanner* é executado em 30 a 50 planos distribuídos em conjuntos de issues, sempre com documentação da cobertura de SRP, OCP, DIP e rastreabilidade à taxonomia. Para RQ2, coleta-se o delta SOLID

por issue e por condição, registrando o número de violações antes e depois das mudanças.

Para RQ3, constrói-se um corpus de 30 a 50 tarefas-base e, para cada uma, geram-se dez paráfrases. Isso produz 300 a 500 execuções no total, todas com registro de *verdict* sob as duas condições. Para RQ4, filtra-se o subconjunto *legacy* definido a priori e repete-se o experimento pareado. Para RQ4a, introduz-se a variação de *strictness*, com três níveis configuracionais, **low**, **medium** e **high**, medindo distribuição de *verdicts*, delta SOLID, taxa de aceitação e taxa de escalonamento.

Durante toda a coleta, monitoram-se falhas de modelo, erros de análise, *timeouts* e corrupção de dados. Ao final de M15, executa-se validação formal da qualidade dos dados, verificando *missing values*, outliers, falhas de LLM e integridade de *provenance*. O resultado esperado é um conjunto de dados versionado, anonimizado e pronto para análise preliminar.

Ciclo 3b: Rigor – Análise Preliminar I (Setembro–Outubro de 2027 / Meses 16–17)

Antes da análise confirmativa, executa-se uma fase preliminar para detectar anomalias e autorizar eventuais refinamentos pontuais. Primeiro, realiza-se *data cleaning*, verificando consistência das versões de regras, *model tags*, sementes, parâmetros e completude dos registros. Em seguida, conduz-se análise exploratória. Para RQ1, revisam-se planos amostrados e observa-se se a cobertura ainda se mantém em 80% ou mais. Para RQ2, calcula-se o delta preliminar, incluindo mediana, dispersão e inspeção da forma da distribuição. Para RQ3, observa-se a razão preliminar de consistência sob paráfrases. Para RQ4 e RQ4a, analisam-se respectivamente o efeito no subconjunto *legacy* e o comportamento visual das configurações de *strictness*.

No início de M17, os resultados são discutidos com o orientador. Caso surjam anomalias fundamentais, como efeito muito fraco, distribuição altamente assimétrica ou falhas sistemáticas em um subconjunto do corpus, documentam-se as adaptações necessárias como alterações pós hoc. Caso contrário, define-se o *protocol lockdown*. A partir daí, hipóteses, baselines, variáveis e testes estatísticos ficam congelados, e o código de análise recebe uma tag específica de versionamento.

Ciclo 3b: Rigor – Análise Confirmativa I (Julho–Outubro de 2027 / Meses 16–19)

Em paralelo à fase preliminar, inicia-se a análise confirmativa sob protocolo congelado. Para RQ1, conduz-se uma revisão formal de 15 a 20 planos, verificando cobertura, explicitação de restrições e rastreabilidade à taxonomia. Para RQ2, aplica-se o teste de Wilcoxon *signed-rank* pareado sobre os 30 a 50 pares de delta SOLID, reportando mediana, intervalo de confiança de 95%, valor de p e tamanho de efeito $r = Z/\sqrt{N}$. Para RQ3,

aplica-se o teste de McNemar sobre os *verdicts* obtidos sob paráfrases. Para RQ4, repete-se Wilcoxon no subconjunto *legacy*. Para RQ4a, utiliza-se ANOVA ou Kruskal–Wallis conforme a distribuição dos dados, seguido de pós hoc adequado.

Na mesma fase, aplica-se correção para comparações múltiplas, seja por Bonferroni, seja por Benjamini–Hochberg. Paralelamente, executa-se um estudo de validação humana com ao menos três engenheiros, que rotulam de forma independente uma amostra estratificada de saídas, permitindo calcular κ tanto para o *overall verdict* quanto para adoção de padrão. Também se aplica um survey com escala Likert de cinco pontos cobrindo confiança, controle percebido e usabilidade, com análise descritiva, alfa de Cronbach e correlações de Spearman.

Ao final de M19, consolida-se a seção de resultados com tabelas, gráficos e narrativa científica capazes de sustentar a redação do primeiro artigo.

Ciclo 3c: Escrita e Submissão I (Outubro–Dezembro de 2027 / Meses 16–20)

Em paralelo com a análise confirmativa, inicia-se a redação de um artigo para venue de conferência. Entre M16 e M17, redige-se a introdução, descrevendo problema, motivação prática, lacuna de pesquisa e alinhamento com DSR. Em M17, escreve-se a seção de trabalhos relacionados, cobrindo benchmarks e agentes relevantes, assim como literatura de qualidade de software e modernização. Entre M17 e M18, redige-se a metodologia DSR, explicando os três ciclos e o papel de cada um na robustez do estudo. Em M18, descrevem-se o artefato e o desenho experimental. Em M19, escreve-se a seção de resultados com base nos achados confirmativos.

Entre M19 e M20, o texto passa por revisão interna com o orientador. Em seguida, escolhe-se a venue mais adequada, ajusta-se o artigo ao template LaTeX correspondente e realiza-se a submissão. O resultado esperado ao final de M20 é um artigo submetido, com número de rastreamento, além de um pacote inicial de replicação com dados e código analítico versionados.

Ciclo 3d: Coleta de Dados II (Novembro–Dezembro de 2027 / Meses 21–22)

Enquanto a submissão do primeiro artigo é finalizada, inicia-se a segunda coleta. A estratégia é definida com o orientador entre três possibilidades: replicação em novo subconjunto dos mesmos repositórios, expansão para novos repositórios com perfil *legacy*, ou subanálise focada em um padrão observado no ciclo anterior. Assumindo a estratégia de replicação em novo subconjunto, executam-se novamente as coletas para RQ1 a RQ4a em 30 a 50 pares adicionais, mantendo o protocolo congelado, os controles de qualidade dos dados e os requisitos de *provenance*.

Ciclo 3e: Análise Preliminar II (Janeiro–Fevereiro de 2028 / Meses 23–24)

Em janeiro de 2028, repetem-se os procedimentos de *data cleaning* e análise exploratória para a segunda coleta. O objetivo é comparar os deltas preliminares e os tamanhos de efeito entre o primeiro e o segundo ciclo. Em fevereiro, esses resultados são discutidos com o orientador para verificar se o segundo ciclo confirma, complementa ou contradiz de forma substantiva os resultados anteriores. Na metade de M24, define-se o segundo *protocol lockdown*, e o código analítico recebe uma nova tag de versionamento.

Ciclo 3e: Análise Confirmativa II (Março–Abril de 2028 / Meses 25–26)

Durante março e abril de 2028, executa-se a análise confirmativa da segunda coleta. Repetem-se Wilcoxon, McNemar, Kruskal–Wallis, validação humana e survey, agora focados no material do segundo ciclo. Em paralelo, conduz-se uma meta-análise ou análise combinada dos ciclos I e II, por meio de efeitos agregados, valores de p combinados e testes de heterogeneidade. Se os dois ciclos convergirem, reforça-se a robustez do artefato e do protocolo. Se divergirem, a divergência é tratada como resultado relevante, com potencial valor explicativo para discussão de subgrupos, limitações e validade externa.

Ciclo 3f: Escrita e Submissão II (Abril–Maio de 2028 / Meses 27–29)

Em abril de 2028, inicia-se a redação do artigo final para journal, com integração dos resultados dos dois ciclos. Atualizam-se introdução e trabalhos relacionados, agora incorporando a replicação interna como elemento central da contribuição. Redigem-se a metodologia final, o desenho experimental consolidado, a seção de resultados integrados e a discussão, enfatizando implicações práticas e teóricas.

Em M28, escreve-se a seção de ameaças à validade, cobrindo validade interna, de construto, externa e de conclusão. Na mesma fase, redige-se a conclusão e o encaminhamento de trabalhos futuros. Entre M28 e M29, realiza-se revisão interna final com o orientador, seguida da adequação ao template do journal selecionado e da submissão formal.

Também em M29, redige-se o capítulo de tese consolidando os 24 meses de pesquisa. Esse capítulo cobre metodologia, desenho do artefato, desenho experimental, resultados, discussão e perspectivas futuras. Em paralelo, prepara-se o pacote final de replicação, incluindo *git hashes*, versões exatas de regras, modelos, *prompts*, amostras anotadas, scripts de reexecução e datasets anonimizados. Ao final do processo, espera-se um artigo de journal submetido, um capítulo de tese maduro e um pacote público de replicação com DOI.

Síntese de Milestones e Decisões Críticas

O cronograma de 24 meses contém marcos críticos nos quais decisões *go/no-go* são tomadas. Em M4, avalia-se se as RQs estão operacionalizadas, se o corpus foi validado e se o pré-registro foi congelado. Em M9, verifica-se se a infraestrutura experimental está estável, se o piloto atingiu $\kappa \geq 0,6$ e se o determinismo está sob controle. Em M17, decide-se se o protocolo pode ser congelado para a análise confirmativa. Em M20, verifica-se a prontidão para submissão do primeiro artigo. Em M24, avalia-se a coerência entre o primeiro e o segundo ciclo antes do segundo congelamento do protocolo. Em M26, examina-se se a meta-análise sustenta robustez suficiente para a escrita final. Em M29, consolida-se a submissão do artigo de journal, o arquivamento do pacote de replicação e a redação do capítulo de tese.

Estrutura DSR Alinhada com Hevner et al.

Todo o cronograma é fundamentado nos sete princípios de Hevner et al. [4]. O artefato é concebido e refinado ao longo dos ciclos de design e rigor; a relevância do problema é estabelecida na fase inicial com base em modernização de software legado e necessidades de desenvolvedores; a avaliação combina piloto, análise preliminar, análise confirmativa, validação humana e survey; a contribuição de pesquisa é explicitada pelo *Gap Ledger*; o rigor aparece no pré-registro, nos testes estatísticos, na correção para comparações múltiplas e na replicação; o design é tratado como processo de busca com refinamentos controlados; por fim, a comunicação científica é endereçada por meio de artigo de conferência, artigo de journal e capítulo de tese.

Essa combinação de três ciclos DSR com dois ciclos completos de coleta, análise e escrita busca oferecer robustez metodológica, replicação interna e condições reais de publicabilidade em múltiplos canais científicos.

Versionamento e Status

v1.0 (31 de maio de 2026): cronograma de 14 meses com *feedback loops* explícitos.

v2.0 (31 de maio de 2026): cronograma de 24 meses com dois ciclos DSR completos.

Status: pronto para execução, condicionado à assinatura do orientador em M1.

Próximo passo: assinar o documento de cronograma com o orientador e iniciar a fase 1 em junho de 2026.

Referências

- [1] Basili, V. R., Selby, R. W., and Hutchens, D. H. Experimentation in software engineering. *IEEE Transactions on Software Engineering*, 12(7):733–743, 1986.
- [2] Feathers, M. *Working Effectively with Legacy Code*. Prentice Hall, 2004.

- [3] Fowler, M., Beck, K., Brant, J., Opdyke, W., and Roberts, D. *Refactoring: Improving the Design of Existing Code*. Addison-Wesley, 1999.
- [4] Hevner, A. R., March, S. T., Park, J., and Ram, S. Design science in information systems research. *MIS Quarterly*, 28(1):75–105, 2004.
- [5] International Organization for Standardization and International Electrotechnical Commission. *Systems and Software Engineering – Systems and Software Quality Requirements and Evaluation (SQuaRE) – Quality Models*. Geneva, 2023.
- [6] Martin, R. C. The SOLID principles. Object Mentor, 2003.
- [7] Seacord, R. C., Plakosh, D., and Lewis, G. A. *Modernizing Legacy Systems: Software Technologies, Engineering Processes, and Business Practices*. Addison-Wesley, 2003.
- [8] Wohlin, C., Runeson, P., H"ost, M., Ohlsson, M. C., Regnell, B., and Wesslén, A. *Experimentation in Software Engineering*. Springer, 2012.
- [9] Yang, J., Jimenez, C. E., Wettig, A., Lieret, K., Yao, S., Narasimhan, K., and Press, O. SWE-agent: Agent-computer interfaces enable automated software engineering. *arXiv preprint arXiv:2405.15793*, 2024.